

CASE GC

Thalita Souza - Jul/21



Parte 1 - Feature 'Missões'

“O time de Digital Sales está projetando uma feature para assinantes chamada Missões, uma ferramenta que fará com que jogadores sejam recompensados pela sua recorrência de assinatura. “

Principais indicadores e métricas

- 1) **Lifetime value**, para entender se o valor do ciclo de vida do cliente tem alguma modificação;
- 2) **RFV**, também uma medida de avaliar o valor do ciclo de vida do cliente, porém atribui pesos diferentes para a recência, frequência e valor monetário desse cliente.
- 3) **Métricas de engajamento** (tempo de permanência na página, consumo de conteúdo por usuário, taxa de recorrência de visitas no site, etc.). Um teste A/B aqui seria muito bom!
- 4) **Satisfação geral do usuário** (NPS, análise de sentimentos, etc.)



Parte 2 - Parte prática

Parte 3 - Modelo preditivo

Será que conseguimos prever quais players não irão jogar no mês seguinte?

Porque isso é importante?

- 1) A partir desses dados é possível direcionar campanhas específicas para players novos, para que eles não percam o engajamento inicial;
- 2) Evitar o abandono da plataforma nos primeiros meses de cadastro.

Qual a base utilizada para fazer esse case?

- Base de players com data de cadastro entre nov e dez/19, e que tinham ao menos 1 partida jogada entre jan e fev/20;
- Total de 850 players;
- Variáveis utilizadas.





Algumas técnicas utilizadas

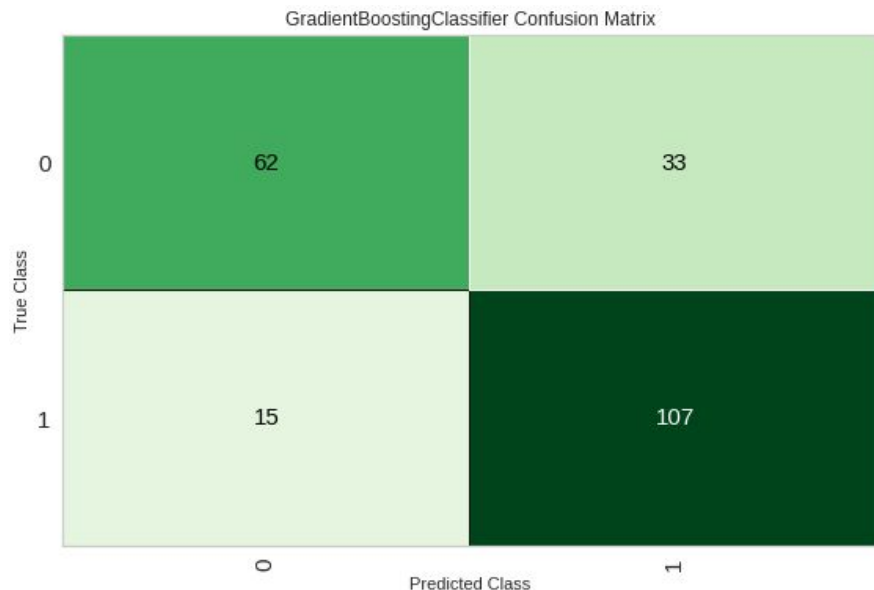
- Preenchimento de nulos com '0';
- Criação de novas variáveis: tempo_cadastro, win_rate, hs_rate, kills_per_match, death_per_match, assist_per_match;
- Remoção das variáveis que não tinham poder explicativo (win_rate e hs_rate);
- Treino/validação do modelo de classificação (GradientBoostingClassifier);
- Tunagem (procura pelos melhores hiperparâmetros);
- Predição na base que nunca tinha sido “vista”;
- Análise de desempenho do modelo (métricas e gráficos);
- Encapsulamento do modelo.



Alguns resultados



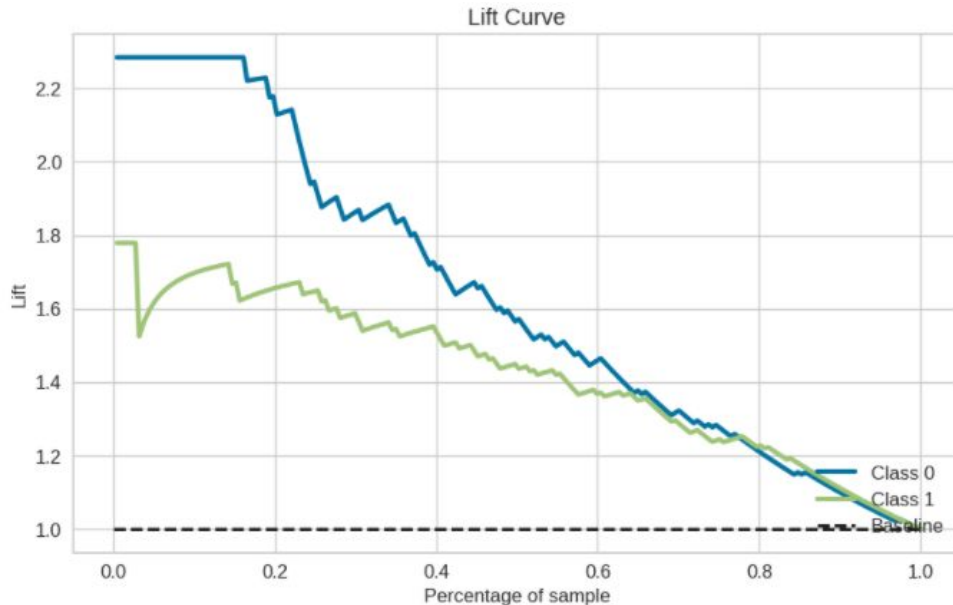
Alguns resultados



- O modelo acertou 80% das vezes em prever quem não ia jogar (classe 0);
- E também acertou em 76% das vezes em prever quem ia jogar (classe 1).



Alguns resultados




- Para ajudar a equipe de marketing, nós podemos ordenar os scores e trabalhar com 20% da base.
- Dessa forma, eu tenho uma expectativa de ter um lift de 1.7, ou seja, utilizar o modelo me traria um ganho de 70% em relação a não fazer nada. :)



Alguns resultados

- A variável tempo de cadastro apareceu como sendo a que tem um peso maior na classificação de quem vai jogar ou não.



Possíveis melhorias

- Adicionar mais variáveis;
- Validar com amostras de outros meses;
- Incluir componentes de sazonalidade e tendência.



Tks! :D



link do repositório do projeto:
https://github.com/thalicsouza/cs_go_analysis